

Projet : Analyse Exploratoire et Visualisation de Données sur un Dataset Kaggle Bachelor 2 Ynov

Objectif :

Permettre aux étudiants d'appliquer les concepts d'analyse exploratoire de données (EDA) et de visualisation à partir d'un jeu de données de leur choix issu de Kaggle. Le projet suit un processus similaire au notebook exemple (jeu de données Iris) : nettoyage, transformation, enrichissement et visualisation des données.

1. Sélection du jeu de données

- Choisissez un dataset intéressant sur Kaggle.
- Critères : au moins 10 variables et 3000 lignes, mélange de variables quantitatives et qualitatives, présence potentielle de valeurs manquantes.
- **Livrable** :
 - Nom et URL du dataset
 - Brève explication (1-2 phrases) du choix

2. Importation des données

- Téléchargez le dataset depuis Kaggle.
- Utilisez Google Colab ou Jupyter Notebook.
- Importez les bibliothèques nécessaires (`pandas`, `numpy`, `matplotlib`, `seaborn`, `plotly`).
- Chargez le dataset dans un DataFrame pandas.
- **À inclure** :
 - Code d'importation des bibliothèques
 - Code de chargement du dataset

3. Exploration initiale

- Affichez l'entête du DataFrame.

- Vérifiez la taille.
 - Listez les colonnes.
 - Identifiez les types de données.
 - Résumé statistique des variables quantitatives.
 - Résumé statistique des variables qualitatives.
 - **À inclure** :
 - Code et sorties pour chaque étape
-

4. Gestion des valeurs manquantes

- Vérifiez la présence et le nombre de valeurs manquantes par colonne. Appliquez une stratégie d'imputation adaptée (moyenne, médiane, mode, suppression, etc.) et justifiez vos choix. Si aucune valeur manquante, simulez-en pour pratiquer.
 - Vérifiez l'absence de valeurs manquantes après imputation.
 - **À inclure** :
 - Code de vérification, d'imputation et de contrôle
 - Commentaires expliquant vos choix
 -
-

5. Enrichissement des données (Feature Engineering) *(Optionnel mais recommandé)*

- Créez au moins une nouvelle variable pertinente à partir des variables existantes (ex : aire, année/mois, etc.).
 - Justifiez la création et son intérêt pour l'analyse.
 - **À inclure** :
 - Code de création de la variable
 - Justification
-

6. Visualisation des données

- Réalisez au moins 5 visualisations différentes :
- Types recommandés : nuage de points, histogramme, boîte à moustaches, diagramme circulaire, carte de chaleur de corrélation, etc.
- Utilisez `matplotlib`, `seaborn` et/ou `plotly` pour des graphiques interactifs.
- Chaque graphique doit avoir un titre et des axes correctement étiquetés.

- Pour chaque visualisation, rédigez une brève interprétation.
- **À inclure** :
- Code pour chaque graphique
- Interprétation en markdown

7. Discrétisation / Binning (*Optionnel mais recommandé*)

- Si pertinent, discrétisez une ou plusieurs variable quantitative en catégories (ex : "Small", "Medium", "Large") ou de votre choix
- Affichez la distribution de la nouvelle variable catégorielle.
- **À inclure** :
- Code de discrétisation
- Visualisation de la distribution

8. Organisation et documentation du Notebook

- Structurez votre notebook avec des titres et sous-titres en markdown.
- Ajoutez des commentaires dans le code pour expliquer les étapes importantes.
- Rédigez :
- Une introduction présentant le dataset et l'objectif du projet
- Une conclusion résumant les principales découvertes

Évaluation

Le projet sera évalué sur :

- Pertinence du dataset choisi
- Qualité de l'exploration initiale
- Gestion des valeurs manquantes et justification
- Création d'une nouvelle variable pertinente (si réalisée)
- Qualité et variété des visualisations
- Interprétations des graphiques
- Organisation et clarté du notebook
- Respect des consignes

Modalités de soumission

- À rendre : fichier `.ipynb` (Google Colab ou Jupyter Notebook) incluant code, sorties (tableaux, graphiques) et commentaires/explications en markdown.
 - Le notebook doit être exécutable de façon autonome.
-

Conseils

- Commencez par des visualisations simples avant d'explorer les relations entre variables.
 - Testez plusieurs types de graphiques pour trouver le plus pertinent.
 - Si le dataset est volumineux, travaillez sur un échantillon.
 - Inspirez-vous du notebook exemple pour la syntaxe et la démarche.
-

Bonne chance pour votre projet !